

1. O que são os Componentes Principais?

- **Componentes Principais** são combinações lineares das variáveis originais, criadas de forma que cada componente sucessivo capture a maior quantidade possível da variância restante dos dados.
- O primeiro componente principal (**PC1**) captura a maior variância possível presente no conjunto de dados. Ele é uma “direção” nos dados que melhor representa a dispersão máxima.
- O segundo componente principal (**PC2**) captura a maior variância possível que ainda resta após o primeiro componente e é ortogonal (não correlacionado) ao primeiro. Isso significa que os componentes não compartilham variância entre si.
- Esse processo continua até que haja tantos componentes quanto variáveis originais, mas, geralmente, apenas alguns componentes iniciais (PC1, PC2, etc.) explicam a maior parte da variância e são retidos para a análise.

2. Interpretação dos Componentes

a. Variância Explicada

- Cada componente principal explica uma porcentagem da variância total dos dados.
- A **proporção de variância explicada** é uma métrica importante: por exemplo, se os dois primeiros componentes (PC1 e PC2) explicam 80% da variância, isso indica que esses componentes conseguem representar bem os dados com 80% da informação original.
- Geralmente, usamos um **scree plot** para visualizar essa variância explicada por componente. O ponto onde o gráfico começa a “achatar” (o “cotovelo”) indica o número ideal de componentes a serem retidos.

b. Cargas dos Componentes (Loadings)

- As **cargas** representam a correlação entre cada variável original e o componente principal. Elas nos dizem o quanto cada variável contribui para o componente.
- Em um biplot (gráfico bidimensional com PC1 e PC2), as variáveis que têm cargas altas no mesmo componente aparecem próximas umas das outras, indicando que estão relacionadas.

c. Coeficientes dos Componentes (Scores)

- Os **scores** são as projeções das observações nos componentes principais, indicando como cada observação se posiciona ao longo dos componentes. Em um biplot, cada ponto representa uma observação no espaço definido pelos componentes.
- As posições dos pontos no biplot mostram como as observações (por exemplo, marcas ou produtos) se diferenciam em relação aos componentes principais. Isso ajuda a identificar padrões ou agrupamentos entre as observações.

3. Exemplo de Interpretação de um Biplot

Suponha que você tenha um biplot com as variáveis “valor”, “desempenho” e “diversão” posicionadas de forma próxima umas das outras no PC1, enquanto “inovação” e “tendência” estão no PC2. Aqui estão algumas interpretações possíveis:

- As variáveis próximas no gráfico estão **correlacionadas positivamente** e contribuem de forma semelhante para o componente. Por exemplo, se “valor” e “desempenho” estão próximos, isso indica que marcas ou produtos bem avaliados em “valor” tendem a ser bem avaliados em “desempenho”.
- As variáveis posicionadas mais distantes indicam **correlações negativas** ou contribuições diferentes entre os componentes. Por exemplo, se “tendência” está distante de “valor”, isso sugere que esses aspectos podem estar em oposição no grupo analisado.
- As observações (marcas ou produtos) localizadas próximas a determinadas variáveis no gráfico indicam que possuem alta pontuação nesses atributos.

4. Interpretação das Coordenadas dos Componentes (Scores)

Imagine que, após aplicar a PCA, você analisa os **scores** dos componentes principais:

- Observações com **altos scores** em um componente (por exemplo, em PC1) são aquelas que possuem maior variância explicada por esse componente. Isso pode significar que esses elementos são fortemente caracterizados por determinadas variáveis que têm alta carga nesse componente.
- O valor dos scores ajuda a entender o **posicionamento relativo** das observações. Marcas que estão próximas no gráfico de componentes principais compartilham características semelhantes, enquanto marcas distantes são mais diferentes em termos das variáveis consideradas.

5. Exemplo Prático

Suponha que você está analisando um conjunto de dados de avaliações de marcas em vários atributos, como “qualidade”, “inovação”, “custo-benefício”, etc. A PCA pode mostrar que:

- **PC1** representa algo como “qualidade” e “custo-benefício”, enquanto **PC2** representa “inovação” e “atualidade”.
- Se uma marca tem um score alto em **PC1**, ela provavelmente é bem vista em termos de qualidade e custo-benefício.
- Se uma marca tem um score alto em **PC2**, ela pode ser vista como inovadora e moderna, mas talvez não tenha avaliações tão boas em relação ao custo-benefício.

Esses insights podem ajudar a identificar quais dimensões principais diferenciam as marcas e como elas se comparam umas com as outras.

Resumo dos Passos de Interpretação

1. **Verifique a variância explicada** por cada componente para decidir quantos manter.

2. **Observe as cargas dos componentes** para entender o que cada componente representa.
3. **Análise o biplot** para ver como as variáveis e as observações estão relacionadas entre si.
4. **Use os scores** para interpretar o posicionamento relativo das observações (marcas ou produtos) ao longo dos componentes.

Com a PCA, você pode simplificar dados complexos e focar nas dimensões mais importantes, facilitando a criação de estratégias baseadas em insights claros sobre como as variáveis interagem e quais aspectos diferenciam as observações.

1. Carregar e Visualizar Dados

```
brand.ratings <- read.csv("http://goo.gl/IQl8nc")  
head(brand.ratings)  
tail(brand.ratings)
```

Objetivo: Carregar o conjunto de dados de avaliações de marcas diretamente de uma URL e visualizar as primeiras e últimas linhas para conferir se os dados foram carregados corretamente.

`head(brand.ratings)` exibe as primeiras linhas e `tail(brand.ratings)` exibe as últimas, permitindo uma inspeção inicial das variáveis e estrutura dos dados.

2. Resumo e Estrutura dos Dados

```
summary(brand.ratings)  
str(brand.ratings)
```

Objetivo: Obter um resumo estatístico dos dados (`summary()`) e verificar a estrutura das variáveis (`str()`). `summary()` exibe as estatísticas básicas (mínimo, quartis, mediana, média, máximo) de cada coluna. `str()` mostra o tipo de cada variável e o número total de observações, ajudando a garantir que as variáveis estejam no formato adequado (numéricas para as avaliações, fator para as marcas).

3. Reescalamento dos Dados

```
x <- 1:1000  
x.sc <- (x - mean(x)) / sd(x)  
summary(x.sc)
```

Objetivo: Demonstrar o processo de normalização, onde uma variável (`x`) é centralizada (subtraindo a média) e redimensionada (dividindo pelo desvio padrão).

Esta etapa transforma os dados em uma escala de Z-score, onde a média é 0 e o desvio padrão é 1. Isso é útil para padronizar dados e facilitar comparações entre variáveis em escalas diferentes.

4. Reescalonar todas as Variáveis

```
brand.sc <- brand.ratings
brand.sc[, 1:9] <- data.frame(scale(brand.ratings[, 1:9]))
summary(brand.sc)
```

Objetivo: Reescalar todas as variáveis de avaliação (colunas de 1 a 9) para que cada variável tenha média 0 e desvio padrão 1.

`scale()` realiza esse reescalonamento de forma automática para todas as colunas numéricas selecionadas, facilitando comparações diretas entre diferentes atributos.

5. Visualizar Correlação com corrplot

```
library(corrplot)
corrplot(cor(brand.sc[, 1:9]), order="hclust")
```

Objetivo: Gerar um gráfico de correlação entre as variáveis (adjetivos) reescaladas.

`corrplot()` exibe a matriz de correlação com cores, onde `order="hclust"` agrupa variáveis semelhantes em clusters, facilitando a visualização de relações fortes entre os atributos das marcas.

6. Agregação: Calcular a Média das Avaliações por Marca

```
brand.mean <- aggregate(. ~ brand, data=brand.sc, mean)
brand.mean
```

Objetivo: Calcular a média de cada variável (adjetivo) para cada marca, agrupando os dados por marca.

`aggregate()` facilita a criação de um data frame com médias para cada combinação de marca e adjetivo, o que é útil para análises de posicionamento e comparações diretas entre marcas.

7. Ajustes no Data Frame de Médias

```
rownames(brand.mean) <- brand.mean[, 1]
brand.mean <- brand.mean[, -1]
```

Objetivo: Melhorar a apresentação do data frame `brand.mean`.

Nomeamos as linhas com os rótulos das marcas (`brand.mean[, 1]`) e, em seguida, removemos a coluna `brand` para evitar redundância.

8. Criar um Heatmap das Médias dos Adjetivos por Marca

```
library(gplots)
library(RColorBrewer)
```

```
heatmap.2(as.matrix(brand.mean),  
          col=brewer.pal(9, "GnBu"), trace="none", key=FALSE, dend="none",  
          main="\n\n\n\nAtributos da Marca")
```

Objetivo: Visualizar as médias dos adjetivos por marca usando um heatmap, que colore os valores conforme a intensidade, facilitando a identificação de marcas bem avaliadas em determinados atributos.

`heatmap.2()` cria o gráfico, com cores da paleta “GnBu” do `RColorBrewer`, destacando os valores com cores que vão do verde (baixo) ao azul escuro (alto).

9. Análise de Componentes Principais (PCA)

```
brand.pc <- prcomp(brand.sc[, 1:9])  
summary(brand.pc)
```

Objetivo: Reduzir a dimensionalidade dos dados e identificar padrões principais nas avaliações.

`prcomp()` realiza a PCA nas variáveis de avaliação, e `summary()` mostra a variância explicada por cada componente, ajudando a entender a importância de cada fator na explicação da variabilidade dos dados

10. Gráfico Scree Plot da PCA

```
plot(brand.pc, type="l")
```

Objetivo: Visualizar a proporção de variância explicada por cada componente principal. Um scree plot ajuda a decidir quantos componentes principais devem ser mantidos (geralmente onde há um “cotovelo” na curva)

11. Biplot dos Dois Primeiros Componentes Principais

```
biplot(brand.pc)
```

Objetivo: Visualizar a relação entre as variáveis (adjetivos) e as marcas nos dois primeiros componentes principais.

O biplot ajuda a identificar quais adjetivos estão mais relacionados e como as marcas estão posicionadas em relação a esses adjetivos principais.

12. PCA com as Médias Agregadas por Marca

```
brand.mu.pc <- prcomp(brand.mean, scale=TRUE)  
summary(brand.mu.pc)
```

Objetivo: Aplicar a PCA usando as médias de cada marca para cada adjetivo, em vez de todas as observações individuais.

Isso permite identificar padrões e posicionamento das marcas com base nas médias dos adjetivos.

13. Biplot para o Posicionamento das Marcas com a Média dos Adjetivos

```
biplot(brand.mu.pc, main="Posicionamento da Marca", cex=c(1.5, 1))
```

Objetivo: Visualizar as marcas e os adjetivos nos dois primeiros componentes principais com base nas médias.

`cex=c(1.5, 1)` aumenta o tamanho das etiquetas das marcas no gráfico, facilitando a leitura e análise do posicionamento de cada marca.

14. Comparar Diferenças entre Marcas Específicas

```
brand.mean["c", ] - brand.mean["e", ]
```

Objetivo: Calcular a diferença nas médias dos adjetivos entre duas marcas específicas (exemplo: c e e).

Essa comparação ajuda a entender como uma marca se destaca ou se diferencia em relação a outra em atributos específicos

15. Encontrar a Média de Quatro Marcas Específicas e Comparar com uma Marca

```
colMeans(brand.mean[c("b", "c", "f", "g"), ]) - brand.mean["e", ]
```

Objetivo: Calcular a média dos adjetivos para um conjunto de marcas (neste caso, b, c, f, e g) e comparar essa média com uma marca específica (e).

Isso permite avaliar onde uma marca se posiciona em relação à média de um grupo de concorrentes, sendo útil para análises de posicionamento e decisões estratégicas.

Case

História da VittaFit

A VittaFit foi fundada em 2015 por Camila e João, dois jovens empreendedores com a missão de tornar a alimentação saudável acessível para mais pessoas. Eles acreditavam que uma vida equilibrada e nutritiva não deveria ser um privilégio apenas de quem podia pagar caro por produtos de alta qualidade. Assim, criaram a VittaFit, uma marca focada em alimentos funcionais e nutritivos, oferecidos a preços acessíveis e disponíveis em supermercados de todo o país.

Após cinco anos no mercado e com uma base sólida de clientes, Camila e João decidiram fazer um estudo mais profundo sobre o posicionamento da VittaFit em comparação com outras marcas de alimentação saudável. Eles contrataram uma consultoria para realizar

uma análise de mercado que incluía a construção de um mapa perceptual, com o objetivo de entender como os consumidores percebiam a VittaFit em relação a seus concorrentes diretos.

No mapa perceptual, a posição da VittaFit foi analisada junto a várias outras marcas conhecidas, cada uma competindo em diferentes atributos, como qualidade, preço, inovação e imagem de marca. Esse mapa ajudou Camila e João a visualizar o cenário competitivo de uma forma mais clara e ver onde a VittaFit se destacava – e onde ainda havia espaço para melhorias.

Ao analisar o mapa, eles perceberam que a marca estava posicionada de maneira específica em relação aos concorrentes. A partir desse resultado, eles começaram a discutir novas estratégias de marketing para reforçar sua posição onde já eram fortes e explorar áreas onde poderiam se expandir para captar um público ainda maior.

Camila e João optaram por lançar uma campanha que destacasse os benefícios nutricionais dos produtos VittaFit, sem perder o foco no preço acessível. Além disso, consideraram a ideia de desenvolver uma linha premium de produtos, atraindo consumidores interessados em novidades e ingredientes diferenciados, mas mantendo o custo-benefício que é a essência da VittaFit.

Perguntas para os alunos:

- 1. Analisando o gráfico, quais características percebidas pelos consumidores (representadas pelos vetores) são mais associadas à nossa marca (VittaFit)? Como essas características se relacionam com o posicionamento da marca em relação a outras marcas no mercado?**
- 2. Considerando que a VittaFit é percebida como uma marca de bom custo-benefício, próxima aos atributos "bargain" e "value", que tipo de estratégia de comunicação poderíamos adotar para reforçar ou modificar essa percepção no público-alvo?**